

중 간 보 고 서

AI 반려 캐릭터 기반 치매 조기 스크리닝 서비스



분 과 명 : 데이터베이스/그래픽스 및 비전

팀 명 : 효자손

지 도 교 수 : 조준수

팀 원 : 202145815 원준서 wonjunsea@pusan.ac.kr

202345805 김민서 kmmlns@pusan.ac.kr

202345822 이지현 leejihyeon@pusan.ac.kr

목 차

과제 개요

1. 요구조건 및 제약 사항 분석에 대한 수정사항

1.1 데이터 수집 방향 변경

1.2 관련 논문 검토에 따른 모델 변경

1.3 현장 방문 결과에 따른 요구조건 보완

2. 설계 상세화 및 변경 내역

2.1 전체 시스템 처리 구조 변경

2.2 직접 수집 음성 데이터 전처리 설계

2.3 메인 캐릭터 설계 상세화

3. 갱신된 과제 추진 계획

4. 추가할 기능 및 향후 반영 사항

5. 구성원별 진척도

6. 보고 시점까지의 과제 수행 내용 및 중간 결과

6.1 UI/UX 설계

6.2 음향 분석 모델(AST) 베이스라인 실험

6.3 음성인식(STT) 모델 비교 실험

7. 참고 문헌

과제 개요

본 시스템은 고령자가 친근한 3D 캐릭터와 음성 문답을 진행하는 과정에서 수집되는 발화 데이터를 분석하여 인지기능 저하 가능성을 조기에 확인하는 보조적 스크리닝 시스템을 개발하는 것을 목표로 한다. 이는 의료기관의 치매 진단을 대체하는 것이 아니라 일상적·반복적 사용 과정에서 나타나는 음성 및 언어적 변화를 관찰하고 치매안심센터나 병원 검사를 권고하기 위한 참고 정보를 제공한다.

착수 단계에서는 Whisper API를 통한 음성 인식과 KcELECTRA 기반 텍스트 분석을 중심으로 시스템을 설계하였다. 이후 관련 논문 검토와 현장 데이터 수집을 진행하면서 음향적 발화 특징을 분석하는 AST 모델을 추가하고 AI Hub 데이터 중심의 수집 방식에서 경로당과 치매 관련 기관을 방문하여 한국어 고령자 음성 데이터를 직접 수집하는 방식으로 연구 방향을 구체화하였다. 기존 착수보고서에서 제시한 캐릭터 중심 상호작용, 고령자·보호자 화면 분리, 음성 문답, 결과 추이 확인 등의 서비스 구조는 유지하되 AI 모델과 데이터 처리 구조를 중심으로 설계를 변경하였다.

1. 요구조건 및 제약 사항 분석에 대한 수정사항

1.1 데이터 수집 방향 변경

1.1.1 기존 데이터 수집 방향

착수 단계에서는 AI Hub의 「자유대화 음성(노인남여)」 데이터를 정상군 데이터로 활용하고, AI Hub 안심존에서 제공되는 「인지기능 장애 진단 음성/대화」 데이터를 치매 의심군 데이터로 활용하여 학습 데이터셋을 구성할 계획이었다.

그러나 안심존 데이터는 개인정보 및 민감정보 보호를 위해 일반 공개 데이터와 달리 별도의 이용 신청과 승인 절차가 필요하며 지정된 환경에서만 열람·분석할 수 있는 등 활용상의 제약이 크다. 또한 신청 후 실제 데이터 사용 가능 시점을 예측하기 어려워 제한된 졸업과제 수행 기간 안에 데이터를 확보하고 모델 학습과 성능 검증까지 완료하기에는 일정상 위험이 있다고 판단하였다.

이에 따라 안심존 데이터의 승인 여부에 의존하는 방식에서 벗어나 경로당과 관련 기관을 직접 방문하여 인지선별검사를 진행하는 고령자의 음성을 수집하는 방향으로 데이터 수집 계획을 변경하였다. AI Hub의 노인 남녀 자유 대화 음성 데이터는 정상 고령자 발화의 특성을 확인하고

Whisper와 KcELECTRA의 처리 프로토콜을 검증하는 용도로 계속 활용하되 최종 모델 학습과 검증에는 직접 수집한 한국어 정상군 및 인지저하 의심군 데이터를 중심으로 활용할 계획이다.

1.1.2 변경된 데이터 수집 방향

변경된 방향에서는 경로당 및 관련 기관을 직접 방문하여 CIST 인지선별검사를 수행하는 고령자의 음성을 수집한다. 수집 데이터는 검사 대상자의 음성 녹음본과 정상 또는 인지저하 의심 여부에 관한 라벨로 구성하며 검사지 원문과 해설지는 외부로 반출하거나 학습 데이터에 포함하지 않는다. 공개 데이터는 다음과 같이 제한적으로 활용한다.

데이터	활용 목적
AI Hub 노인 남녀 자유 대화 음성	한국어 정상 고령자 음성의 초기 베이스라인을 구성하고 Whisper-KcELECTRA 프로토콜을 검증한다.
DementiaNet 외국어 음성	AST의 1차 베이스라인 실험을 진행한다. 직접 수집한 한국어 데이터로 추가 파인튜닝한 후 성능 향상 여부에 따라 최종 모델에 반영한다.
경로당·기관 직접 수집 데이터	최종 한국어 정상군·의심군 모델 학습 및 평가의 핵심 데이터이다.
CIST 결과 라벨	대상자 단위 정상·의심 라벨 구성에 활용하되 의학적 확진 라벨로 해석하지 않는다.

DementiaNet은 치매 진단 이력이 확인된 공인 및 유명인의 유튜브 음성과 정상인의 음성으로 구성된 공개 데이터이다. 「인지기능 장애 환자의 음성 데이터를 활용한 치매 예측 분류에 관한 연구」^[1]에서는 DementiaNet 외국어 데이터와 직접 수집한 한국어 데이터를 각각 8초 단위로 분할한 뒤 AST 모델을 별도로 학습하여 언어권에 따른 분류 성능을 비교하였으며 외국어 데이터와 한국어 데이터에서 AST가 각각 약 82%와 81%의 정확도를 기록하여 외국어 음성이 치매 관련 음향 특징을 학습하기 위한 보조 데이터로 활용될 가능성을 확인하였다. 다만 이는 외국어와 한국어 데이터를 통합하여 학습한 결과가 아니므로 외국어 데이터가 실제 한국어 대상 모델의 성능을 높이는지는 별도의 검증이 필요하다.

본 과제에서는 DementiaNet을 AST의 전처리·학습·평가 파이프라인이 정상적으로 작동하는지 확인하기 위한 1차 베이스라인 데이터로 활용하고 이후 최종 AST 모델 학습에도 함께 활용한다. 또한 직접 수집한 한국어 정상군 및 인지저하 의심군 데이터를 추가하여 실제 서비스 대상인 한국어 고령자 음성에 적합하도록 모델을 파인튜닝할 예정이다.

1.1.3 직접 수집 데이터의 제약 사항

직접 데이터 수집 과정에서는 다음 사항을 준수한다.

첫째, 데이터 수집 전 대상자 또는 보호자에게 수집 목적, 활용 범위, 보관 방법을 설명하고 동의를 받아야 한다. 이름, 생년월일, 연락처 등 직접 식별 정보는 음성 학습 데이터와 분리하거나 가명화한다.

둘째, CIST는 인지저하 가능성을 선별하는 검사이므로 검사 결과를 치매 확진 라벨로 사용하지 않는다. 의심 결과가 나타난 경우에도 병원에서 추가 검사와 전문의 판단이 필요하다는 점을 시스템과 보고서에 명시한다.

셋째, 검사기관의 명칭, 담당자의 성명, 검사지 및 해설지 등 외부 공개가 제한된 자료는 보고서와 학습 데이터에서 제외한다.

넷째, 경로당과 같이 주변 소음과 다수 화자가 존재하는 환경에서는 대상자의 발화만을 정확히 분리하기 어렵다. 따라서 녹음 환경, 주변 소음, 화자 수, 겹침 발화 여부를 메타데이터로 기록하고 실제 모델 학습 전에 수동 검증을 수행한다.

다섯째, 정상군과 의심군이 서로 다른 장소에 집중되지 않도록 구성해야 한다. 특정 시설의 소음이나 마이크 특성이 라벨과 결합되면 모델이 인지기능이 아니라 녹음 장소를 학습하는 데이터 편향이 발생할 수 있다.

1.2 관련 논문 검토에 따른 모델 변경

1.2.1 AST 모델 추가

관련 논문^[1]에서는 Audio Spectrogram Transformer(AST) 모델을 활용하여 한국어와 외국어 음성에서 정상군과 치매군을 분류하였다. 연구 결과 한국어 데이터에서는 AST 정확도 0.813, CNN 정확도 0.745, Wav2Vec2 정확도 0.738이었으며 외국어 데이터에서는 AST가 정확도 0.827을 기록하였다. 관련 연구는 음성 분류에서 언어 자체뿐 아니라 발화 속도, 진폭, 세기 등의 음향적 특징이 중요한 분류 근거가 될 가능성을 제시하였다.

이에 따라 본 과제는 기존의 텍스트 분석 중심 구조에 AST를 추가한다. AST는 음성을 Log-Mel Spectrogram으로 변환하고 이를 작은 패치로 나누어 Transformer가 분석하는 오디오 분류 모델이다. 이를 통해 다음과 같은 발화 방식의 특징을 학습하는 것을 목표로 한다.

분석 요소	의미
발화 속도	평소보다 느린 발화 또는 발화량 감소 여부
침묵과 망설임	답변 중 긴 멈춤이나 반복적인 주저 표현
음성 에너지	음량과 진폭의 불규칙성
주파수 패턴	정상군과 다른 음향적 변화
발화 안정성	끊김, 반복, 불규칙한 발화 흐름

AST는 음성의 의미를 직접 이해하는 모델이라기보다 고령자가 '어떻게 말했는가'를 분석하는 역할을 담당한다.

1.2.2 KcELECTRA 유지 및 선택 근거 보완

AST가 추가되더라도 KcELECTRA는 최종 모델 구성에서 제외하지 않는다. AST만으로는 답변이 질문에 적절한지, 날짜나 장소를 정확히 답했는지, 같은 표현을 반복하는지 등의 언어적 특징을 충분히 분석하기 어렵기 때문이다.

「BERT를 이용한 발화 기반 치매 환자 위험 탐지 모델」^[2]에서는 KoBERT, KoELECTRA, KcELECTRA, KLUE-RoBERTa를 비교하였으며 KcELECTRA가 정확도 0.9763, 재현율 0.9595, F1-score 0.9644로 가장 높은 결과를 기록하였다. KcELECTRA는 뉴스 댓글과 대댓글 등 비정형 사용자 생성 텍스트로 사전 학습되어 구어체, 생략, 반복 표현 등 실제 발화의 전사문을 처리하는 데 적합한 특성이 있다.

다만 해당 논문은 치매 여부를 직접 분류한 연구가 아니라 치매 환자의 발화에서 위험 상황을 탐지한 연구이다. 따라서 논문의 성능 수치를 본 과제의 치매 스크리닝 성능으로 그대로 적용할 수는 없다. 본 과제에서는 KcELECTRA가 구어체 발화 분류에 적합하다는 모델 선택 근거로 활용하고 직접 수집한 정상·의심 데이터를 이용하여 별도의 파인튜닝과 성능 검증을 수행한다.

KcELECTRA는 Whisper를 통해 변환된 텍스트를 입력받아 다음과 같은 내용적 특징을 분석한다.

분석 요소	예시
질문과 답변의 적절성	요일 질문에 장소를 답하는 경우
지남력 관련 오류	날짜, 계절, 장소를 잘못 답한 경우
기억 관련 표현	"기억이 안 난다"는 표현의 반복
문장 길이	지나치게 짧거나 내용이 없는 답변

어휘 다양성	동일 단어와 표현의 반복
의미 일관성	문장 전후 관계가 맞지 않는 경우

1.2.3 최종 모델 방향

변경된 AI 모델의 핵심은 다음과 같다.



그림 1. 고령자 음성 기반 스크리닝 모델 파이프라인

AST는 고령자가 '어떻게' 말했는지를 분석하고, KcELECTRA는 고령자가 '무슨 말'을 했는지를 분석한다. 두 모델을 결합하면 답변 내용은 맞지만 대답하기까지 오랜 시간이 걸린 경우와 발화는 또렷하지만 질문과 관계없는 답변을 한 경우를 상호 보완적으로 분석할 수 있다. 초기 단계에서는 두 모델을 개별적으로 평가하고 이후 검증 데이터의 성능을 기준으로 단순 평균 또는 가중 평균 방식의 결합을 실험한다.

1.3 현장 방문 결과에 따른 요구조건 보완

경로당 방문 및 치매 관련 실무자 의견을 통해 기존 요구사항을 다음과 같이 보완하였다.

1.3.1 의료적 역할의 명확화

CIST는 인지기능 저하 가능성을 먼저 확인하는 선별검사이며 의심 대상자는 병원에서 추가적인 신경인지검사와 영상검사, 전문의 진료를 통해 상태와 원인을 확인한다. 따라서 본 시스템은 CIST나 병원 검사를 대체하지 않고 반복적인 음성 문답에서 변화 가능성을 확인하여 전문기관 검사를 권고하는 보조도로 정의한다.

결과 화면에서는 '치매 진단', '치매 확률'과 같이 확정적으로 해석될 수 있는 표현보다 '인지기능 저하 의심 신호', '추가 확인 권장', '스크리닝 참고 점수'와 같은 표현을 사용한다.

1.3.2 대상자 특성 정보 추가

인지선별검사는 학력, 문해 여부, 건강 상태 등 대상자의 특성에 따라 결과 해석이 달라질 수 있다. 또한 고혈압, 당뇨, 고지혈증, 음주 및 흡연 등은 인지건강과 관련된 생활·건강 요인으로 관리될 필요가 있다. 이에 따라 회원가입 및 초기 검사 단계에서 연령대, 성별, 최종 학력 또는 교육 연수, 문해 여부, 현재 진단받은 주요 질환, 음주 및 흡연 여부, 청력 또는 의사소통상의 어려움을 선택적으로 입력하도록 요구사항을 수정한다.

해당 정보는 모델이 단독으로 진단을 내리는 근거가 아니라 결과 해석과 사용자별 비교 기준을 보완하는 메타데이터로 활용한다.

1.3.3 고령자 디지털 접근성 강화

현장에서는 스마트폰으로 전화를 받거나 단축번호를 사용하는 것은 가능하지만 문자 입력이나 복잡한 앱 조작에는 어려움을 겪는 사용자가 많다는 의견을 확인하였다. 이에 따라 한 화면에 하나의 주요 기능만 제공하고, 큰 글자와 큰 버튼, 짧은 문장, 명확한 음성 안내를 중심으로 화면을 구성한다.

또한 잘못된 버튼을 눌렀을 때 쉽게 이전 단계로 돌아갈 수 있도록 하고 '다음', '다시 듣기', '처음으로'처럼 익숙한 표현을 사용한다. 착수보고서에서 제시한 시니어 친화적 UI와 음성 중심 입력 요구사항을 유지하면서 음성 선택 및 질문 표시 기능을 추가한다.

1.3.4 녹음 환경 요구사항 보완

경로당은 여러 사람이 대화하거나 TV가 켜져 있는 경우가 많아 검사 정확도와 음성 분리 성능이 저하될 수 있다. 가능하면 별도의 조용한 공간에서 한 명씩 녹음하고 불가능한 경우 주변 소음과 겹침 발화 여부를 기록한다.

인터넷 연결이 불안정한 환경도 고려하여 녹음과 검사 진행은 오프라인에서도 가능하도록 하고 음성 파일과 답변 결과는 기기에 임시 저장한 뒤 인터넷 연결 시 서버에 전송하는 구조를 검토한다.

2. 설계 상세화 및 변경 내역

2.1 전체 시스템 처리 구조 변경

착수보고서의 기존 처리 구조는 다음과 같았다.




그림 2. 착수보고서 시점의 텍스트 기반 처리 구조

중간보고 시점의 변경된 구조는 다음과 같다.




그림 3. 중간보고 시점의 전체 처리 구조

AST와 KcELECTRA의 성능이 충분히 검증되기 전에는 두 결과를 무조건 결합하지 않는다. 우선 모델별 정확도, 정밀도, 재현율, F1-score와 혼동행렬을 각각 확인한 뒤, 결합 모델이 단일 모델보다 실제로 성능을 향상시키는지 비교한다.

2.2 직접 수집 음성 데이터 전처리 설계

전처리 파이프라인의 목표는 전체 녹음에서 검사 대상 고령자의 발화만을 문항 단위로 추출하여 AST와 Whisper-KcELECTRA에 입력할 수 있는 형태로 가공하는 것이다. 전처리의 기본 원칙은 다음과 같다.

인지저하와 관련될 수 있는 침묵, 끊김, 망설임, 발화 속도는 보존하고, 녹음 환경이나 타인 음성과 같이 라벨과 무관한 단서는 제거한다.

2.2.1 전처리 파이프라인



그림 4. 음성 전처리 파이프라인

2.2.2 단계별 설계

단계	적용 방법	주요 내용
앞뒤 트리밍	Silero VAD	녹음 시작 전 준비 구간과 종료 후 잡담을 제거하되 답변 중 침묵은 보존한다.
화자 분리	pyannote.audio	검사자와 대상자의 발화 시점을 구분하고 대상자의 발화만 선택한다.
대상자 식별	검사 구조 및 등록 음성	질문 직후 화자를 대상으로 추정하고 검사 초반 단독 발화의 화자 임베딩을 기준으로 보완한다.
문항 단위 추출	타임스탬프 기반 분할	전체 녹음을 사용하지 않고 질문별 답변 구간으로 저장한다.

겹침 발화 처리	제외 및 사유 기록	다른 사람과 음성이 겹친 구간은 분석에서 제외한다.
소음 제거	조건부 적용	1차 베이스라인에서는 적용하지 않고 성능 저하가 확인될 때만 DeepFilterNet 또는 Demucs를 검토한다.
음량 정규화	EBU R128	마이크 거리와 발성 크기로 인한 음량 편차를 감소한다.
입력 길이 통일	8초 분할	AST 입력을 통일하고 짧은 구간은 패딩 처리한다.
데이터 기록	메타데이터 파일	데이터 출처, 소음 수준, 문항 번호, 전처리 버전, 제외 사유 등을 저장한다.

노이즈 제거는 기본 전처리로 무조건 적용하지 않는다. 과도한 노이즈 제거는 고령자의 불명확한 발음이나 숨소리, 미세한 끊김을 왜곡할 수 있기 때문이다. 원본 데이터로 1차 성능을 측정한 뒤, 경로당 데이터의 STT 오류율이나 AST 성능이 다른 환경보다 명확히 낮을 때만 적용 여부를 판단한다.

화자 분리는 노이즈 제거 전 원본 음성에 수행한다. 노이즈 제거 과정에서 화자 고유의 음성 특성이 손상되면 pyannote의 화자 분리 정확도가 낮아질 수 있기 때문이다.

파일은 P001_Q01_01.wav, P001_Q01_02.wav, P001_Q02_01.wav와 같이 대상자와 문항을 식별할 수 있도록 저장한다. 개인 이름이나 생년월일은 파일명에 포함하지 않으며 대상자 식별자는 별도의 보안 관리 테이블에서 관리한다.

2.3 메인 캐릭터 설계 상세화

2.3.1 캐릭터 도입 배경

본 프로젝트는 노인을 대상으로 하는 AI 기반 치매 선별검사 서비스로, 검사 과정에서 사용자가 심리적인 부담감을 덜 느끼고 보다 자연스럽게 서비스를 이용할 수 있도록 3D 캐릭터를 도입하였다.

고령층은 사회적 고립과 외로움을 경험하는 경우가 많으며 정서적인 교감과 지속적인 상호작용은 삶의 질 향상과 인지 건강 유지에 중요한 요소로 알려져 있다. 또한 반려동물과의 교감은 노인의 우울감 완화와 정서적 안정에 긍정적인 영향을 줄 수 있으며 치매 환자를 대상으로 한 동물매개치료에서도 정서적 안정과 사회적 상호작용 향상 등의 효과가 보고되고 있다.

이에 본 서비스에서는 캐릭터를 단순한 음성 안내 기능이 아닌 사용자와 지속적으로 교감하는 디지털 반려동물의 개념으로 설계하였다. 사용자가 검사 과정에서 친숙함을 느끼고 심리적 부담을 줄일 수 있도록 하며 향후 지속적인 상호작용을 통해 서비스에 대한 몰입감과 친밀감을 높이

는 것을 목표로 한다.

2.3.2 3D 캐릭터 제작

3D 캐릭터는 생성형 AI 기반 3D 모델링 서비스인 Meshy AI를 활용하여 제작하였다. Meshy AI는 텍스트 또는 이미지를 기반으로 3D 모델을 생성할 수 있어 전문적인 모델링 경험이 없더라도 비교적 짧은 시간 안에 원하는 형태의 캐릭터를 제작할 수 있다는 장점이 있다.

캐릭터는 여러 후보를 검토한 결과 강아지를 모티브로 선정하였다. 강아지는 대부분의 연령층에게 친숙하고 긍정적인 이미지를 가지고 있으며 사람 형태의 캐릭터보다 성별이나 연령에 대한 선입견이 적어 누구나 부담 없이 받아들일 수 있다. 또한 실제 반려동물을 연상시키는 친근한 이미지를 통해 사용자와의 심리적 거리를 줄이고, 지속적인 상호작용을 유도할 수 있을 것으로 기대하였다.

캐릭터는 단순한 장식 요소가 아니라 다음 기능을 담당하는 중심 HCI 요소로 활용한다.

- 음성 문답의 시작과 종료 안내
- 질문을 음성으로 읽어주는 진행자 역할
- 다시 듣기, 다음 단계 등 조작 방법 안내
- 검사 진행 상태와 완료 여부 표시
- 반복 사용에 따른 경험치와 성장 상태 표현
- 고령자가 검사를 받는다는 느낌보다 캐릭터와 대화한다는 느낌을 받을 수 있도록 지원




그림 5. Meshy AI를 활용한 3D 캐릭터 제작 화면



그림 6. 제작된 메인 캐릭터

2.3.3 3D 캐릭터 렌더링 및 적용

제작한 3D 캐릭터는 GLB(GLTF Binary) 형식으로 변환하여 웹 환경에서 렌더링할 예정이다. GLB는 3D 모델과 텍스처, 재질, 애니메이션 정보를 하나의 파일에 포함하는 형식으로 웹 기반 3D 콘텐츠 구현에 널리 활용된다.

프론트엔드에서는 React Three Fiber(Three.js 기반)를 활용하여 GLB 파일을 렌더링하고 AI 음성(TTS)과 검사 진행 상황에 따라 캐릭터의 움직임과 표정을 제어할 계획이다. 이를 통해 단순한 이미지가 아닌 사용자와 실시간으로 상호작용하는 3D 캐릭터를 구현할 수 있다.

반면 GIF는 미리 제작된 애니메이션을 반복 재생하는 방식으로, 사용자의 행동이나 서비스 진행 상황에 따라 동작을 변경하거나 표정 및 입 모양을 자연스럽게 표현하는 데 한계가 있다. 따라서 본 프로젝트에서는 향후 립싱크(Lip Sync), 표정 변화 등 다양한 상호작용 기능을 고려하여 GLB 형식을 적용하였다.

구분	GIF	GLB
표현 방식	2D 애니메이션	3D 모델
움직임	미리 제작된 애니메이션 반복	실시간 애니메이션 제어
사용자 상호작용	제한적	가능
표정 및 입모양 변경	어려움	가능

프로젝트 활용	단순 안내 애니메이션	AI 반려 캐릭터 구현
---------	-------------	--------------

3. 갱신된 과제 추진 계획

구분	세부 과업	6월				7월				8월				9월			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
기획	서비스 목표·사용자 흐름 재정의	■	■														
현장 조사	경로당 방문·실무자 의견 수집	■	■	■													
데이터 수집	직접 수집 방향 수립·현장 음성 확보		■	■	■												
공개 데이터	AI Hub-DementiaNet 데이터 확보			■	■	■											
UI/UX	고령자·보호자 화면 설계			■	■	■											
프론트엔드	React Native 목업 구현				■	■	■										
캐릭터	Meshy AI 3D 캐릭터 제작					■	■	■									
KcELECTRA	Whisper-KcELECTRA 프로토콜 검증					■	■	■	■								
AST	DementiaNet 1차 베이스라인 실행						■	■	■								
전처리	직접 수집 데이터 전처리 설계							■	■								
전처리 검증	실제 녹음 샘플 수동 검증							■	■								
모델 학습	한국어 정상·의심 데이터 파인튜닝									■	■						
모델 평가	모델별 성능 비교										■	■	■				
모델 통합	AST-KcELECTRA 결합											■	■	■			
백엔드	사용자·문답·결과 DB API 구현										■	■	■				
통합 테스트	앱-서버-AI 모델 연결												■	■	■		
최종 검증	환경별·대상자별 성능 분석													■	■	■	
마무리	최종 보고서·발표 자료 작성														■	■	■

그림 7. 갱신된 과제 추진 일정

4. 추가할 기능 및 향후 반영 사항

4.1 초기 사용자 정보 입력

고령자가 회원가입 후 최초 검사를 진행할 때 학력과 현재 건강 상태를 입력하도록 한다. 교육 수준이나 문해 여부는 인지검사 응답에 영향을 줄 수 있으므로 결과 해석 시 보조 정보로 활용한다. 주요 입력 항목은 다음과 같다.

항목	활용 목적
최종 학력·교육 연수	교육 수준에 따른 응답 차이 확인
문해 여부	글자 기반 질문 제공 방식 조정
고혈압·당뇨·고지혈증 등	건강 관련 참고 정보
음주·흡연 여부	생활습관 참고 정보

청력 상태	음성 안내 방식과 음량 조정
스마트폰 사용 수준	안내 단계와 조작 난이도 조정

해당 정보는 모델이 치매 여부를 직접 판단하는 결정 변수로 무조건 사용하지 않으며 전문가 검토와 데이터 규모를 고려하여 분석 보조 변수로 활용한다.

4.2 다수 고령자 관리 기능

착수 단계에서는 보호자를 주로 고령자의 자녀나 가족으로 가정하였다. 그러나 현장에서는 치매안심센터 직원, 사회복지사, 경로당 담당자 등 한 명의 검사자가 여러 고령자를 관리하는 상황이 존재할 수 있다. 이에 따라 사용자 관계를 기존의 일대일 연결에서, 보호자-검사자 1명이 여러 명의 고령자 계정을 관리하고 대상자별 검사 기록·문답 요약·추이를 조회할 수 있는 구조로 변경한다.

보호자 또는 검사자는 자신과 연결된 대상자의 정보만 확인할 수 있어야 하며 대상자별 동의 여부와 접근 권한을 관리해야 한다. 가족 보호자와 기관 검사자가 조회할 수 있는 정보 범위도 추후 권한 수준에 따라 구분한다.

4.3 청취 환경 확인 및 음성 선택 절차

치매안심센터 실무자 인터뷰와 실제 검사 참관 과정에서 검사를 시작하기 전에 대상자에게 “어느 쪽 귀가 더 잘 들리세요?”라고 확인한 뒤 잘 들리는 귀의 방향에서 질문을 읽어주는 방식을 확인하였다. 이는 검사 대상자의 청취 상태를 사전에 파악하고 질문을 제대로 듣지 못해 발생할 수 있는 응답 오류를 줄이기 위한 절차이다.

본 서비스에서도 검사 시작 전에 사용자가 어느 쪽 귀로 소리를 더 잘 듣는지 확인하는 안내 절차를 제공한다. 이후 사용자가 스마트폰의 스피커를 잘 들리는 귀 가까이에서 두고 검사를 진행하도록 유도하여 음성 안내를 보다 명확하게 들을 수 있는 환경을 조성하고자 한다.

2024년에 발표된 노화성 난청 관련 연구^[3]에 따르면 노화성 난청은 양쪽 귀에서 점진적으로 진행되는 감각신경성 청력 저하이며 일반적으로 고주파수 영역의 청력 손실이 먼저 두드러진다. 이러한 변화는 단순히 소리의 크기를 작게 느끼는 문제뿐 아니라 말소리, 특히 고주파수 성분이 포함된 음소를 구별하는 능력과 의사소통의 명료도에도 영향을 줄 수 있다. 또한 노화성 난청의 정도와 유형은 개인마다 다르게 나타날 수 있으므로 모든 고령자에게 동일한 음성을 일괄적으로 적용하기보다 사용자가 직접 잘 들리는 음성을 선택할 수 있도록 하는 개인화된 접근이 필요하

다.

이에 따라 서비스 시작 전 서로 다른 음높이와 음색을 가진 음성을 차례로 들려주고 사용자가 가장 명확하고 편안하게 들리는 음성을 선택하도록 한다.

제공되는 음성은 단순히 남성 또는 여성이라는 성별을 기준으로 구분하지 않고 음높이, 발음의 명확성, 말하기 속도와 같은 청취 특성을 기준으로 구성한다. 예를 들어 지나치게 높은 음역은 피하고 안정적인 중간 또는 중저음역을 사용하면서 문장의 각 음절과 단어가 명확하게 전달되도록 한다. 사용자가 선택한 음성은 이후 검사 질문과 시스템 안내에 일관되게 적용한다.

또한 노화성 난청이 있는 고령자는 말소리를 구별하고 내용을 처리하는 데 더 많은 노력이 필요할 수 있으므로 안내 음성의 말하기 속도를 다소 느리게 조절하고 문장 사이에 적절한 간격을 둔다. 질문이 끝난 후에는 충분한 응답 시간을 제공하며 배경음과 불필요한 효과음을 최소화하여 질문 음성이 다른 소리에 가려지지 않도록 한다.

4.4 질문 글자 표시 설정

실제 치매 선별검사는 검사자가 질문을 직접 읽어주며 피검사자에게 검사지를 보여주지 않는 방식으로 진행된다. 이는 질문을 듣고 기억하여 답변하는 과정 또한 인지기능을 평가하는 요소 중 하나이기 때문이다.

그러나 치매안심센터 실무자와의 인터뷰를 통해 청력이 저하된 어르신인 경우 질문을 제대로 듣지 못해 검사의 본래 목적과 관계없이 오답이 발생할 수 있다는 점을 확인하였다. 이에 따라 본 서비스에서는 질문 자막을 기본적으로 비활성화한 상태로 검사를 진행하고 청력 문제로 인해 음성만으로 검사가 어려운 경우에 한하여 검사자 또는 보호자가 자막 표시 기능을 활성화할 수 있도록 구현할 계획이다. 이를 통해 실제 검사 방식을 최대한 유지하면서도 청력으로 인한 검사 오류를 줄이고 접근성을 높이하고자 한다.

4.5 캐릭터 립싱크 기능

치매안심센터 실무자와의 인터뷰를 통해 인지기능이 저하된 어르신은 검사 중 집중력이 떨어지거나 질문과 관련 없는 이야기를 하는 경우가 많으며 검사 과정에서 자연스럽게 집중을 유도하는 것이 중요하다는 점을 확인하였다.

이를 반영하여 AI 음성에 맞추어 캐릭터의 입 모양과 표정이 함께 변화하는 립싱크 기능을 적용하는 것을 검토하고 있다. 캐릭터가 실제로 대화하는 것처럼 표현함으로써 사용자와의 상호작용을 높이고 검사 과정에 대한 집중도와 몰입감을 향상시키는 것을 목표로 한다. 현재 관련 기술

의 적용 가능성을 검토 중이다.

4.6 노인 친화형 UI 개선

치매안심센터 실무자와의 인터뷰를 통해 스마트폰 사용이 익숙하지 않은 고령층은 복잡한 화면 구성보다 직관적이고 단순한 인터페이스를 선호한다는 점을 확인하였다. 이에 따라 한 화면에 하나의 질문만 제공하고, 큰 글씨와 큰 버튼을 적용하며 '다음', '다시 듣기', '처음으로'와 같이 익숙한 표현을 사용하여 조작 부담을 줄일 계획이다. 또한 음성 안내와 화면 안내를 함께 제공하여 고령층의 디지털 접근성을 높이고 보다 편안하게 서비스를 이용할 수 있도록 개선할 예정이다.

향후 개발 과정에서도 실제 검사 환경과 사용자 특성을 지속적으로 반영하여 현장에서 활용 가능한 치매 선별검사 서비스를 구현하는 것을 목표로 한다.

4.7 오프라인 녹음 및 자동 전송

와이파이가 없는 경로당 환경을 고려하여 질문 제공과 음성 녹음은 인터넷 없이도 진행할 수 있도록 설계한다. 녹음 파일과 검사 진행 상태를 기기에 임시 저장하고, 네트워크가 연결되면 서버에 자동 전송한다. 전송 실패 시 데이터가 삭제되지 않도록 '기기 저장 완료', '서버 전송 대기', '서버 전송 완료', '분석 완료'의 상태를 구분하여 관리한다.

5. 구성원별 진척도


구성원	담당 분야	보고 시점까지의 주요 진척도
원준서	프론트엔드·데이터 전처리	공동 UI/UX 설계 React Native 기반 고령자·보호자 목업 구현 직접 수집 음성의 VAD·화자 분리·문항 분할·정규화·8초 분할 전처리 구조 설계
김민서	텍스트 분석 프로토콜	공동 UI/UX 설계 AI Hub 노인 남녀 자유 대화 음성 데이터 확보 음성 입력에서 Whisper STT를 거쳐 KcELECTRA 입력까지 전달되는 전체 프로토콜 검증
이지현	음성 분석 모델	공동 UI/UX 설계 DementiaNet 외국어 정상·치매 음성 데이터 전처리 AST 기반 정상·치매 분류 베이스라인 학습 및 평가 실험

6. 보고 시점까지의 과제 수행 내용 및 중간 결과

6.1 UI/UX 설계


팀 공동으로 서비스의 화면 흐름을 설계하고 React Native 기반으로 주요 화면 목업을 구현하였다. 화면은 공통 온보딩, 고령자 화면, 보호자 화면의 세 그룹으로 구성된다. 공통 온보딩은 서비스 소개와 로그인, 고령자·보호자 사용자 유형 선택으로 이어지며 고령자 화면은 한 화면에 하나의 주요 기능만 제공하는 단순한 구조와 큰 글자 및 큰 버튼, 음성 중심 안내를 원칙으로 설계하였다. 보호자 화면은 피보호자의 상태와 기록을 확인할 수 있도록 구성하였다. 그룹별 주요 화면과 기능은 다음과 같다.

6.1.1 공통 온보딩 화면



시작 화면

메모케어 서비스를 소개하고 로그인 또는 서비스 시작으로 연결한다.



로그인


기존 계정으로 로그인하거나 새 계정을 생성할 수 있다.



사용자 유형 선택


고령자 또는 보호자 중 서비스 이용 유형을 선택한다.

6.1.2 고령자 화면



CIST 검사

초기 CIST 선별검사를 통해 인지 건강 상태를 확인한다.




홈

AI 정서 문답, 일기, 캠페인 등 고령자용 주요 기능으로 이동한다.




AI 정서 문답

AI 캐릭터와 대화하며 정서 상태와 일상을 기록한다.




결과·일기

AI 대화 결과를 확인하고 해당 내용을 일기로 기록한다.



달력 일기

날짜별로 작성된 일기와 활동 기록을 달력에서 확인할 수 있다.



지역 캠페인


지역 인지 건강 캠페인과 프로그램을 확인하고 참여할 수 있다.



알림


검사 일정, 활동 안내 및 서비스 이용 관련 소식을 확인한다.

6.1.3 보호자 화면



대시보드

피보호자의 인지 점수, 위험 상태 및 주요 활동 지표를 한눈에 보여준다.



일기·반응

피보호자가 작성한 일기를 확인하고 반응이나 메시지를 남긴다.



위험 추이 차트

기간별 인지 점수 변화와 위험도 추이를 차트로 보여준다.



알림

인지 점수 하락, AI 대화 완료 및 캠페인 참여 현황을 알려준다.

6.2 음향 분석 모델(AST) 베이스라인 실험

6.2.1 실험 개요

직접 수집한 CIST 데이터의 전처리 및 학습에 앞서 공개 데이터셋인 DementiaNet을 사용하여 AST 기반 음성 분류 파이프라인이 정상적으로 동작하는지 확인하고 예비 성능을 측정하였다. 본 단계에서 AST는 DementiaNet 영어 치매군·비치매군 데이터로 실제 학습과 성능 평가까지 수행하였으며 확인 항목은 AST 파인튜닝의 정상 동작 여부, Accuracy, Precision, Recall, F1 등 분류 성능, GPU 메모리 사용량, 학습 시간, 과적합 여부이다. 실험은 Google Colab(T4 GPU) 환경에서 수행하였고 데이터와 결과물은 Google Drive의 표준화된 폴더 구조로 관리하였다.

전처리는 Colab 노트북으로 자동화하였으며 원본 wav 파일의 정상 여부 확인, 16kHz mono 변환, 8초 단위 segment 생성, AST 학습용 metadata CSV 생성 과정으로 구성된다. 특히 동일 화자의 음성이 train과 validation에 동시에 포함되지 않도록 화자 단위로 데이터를 분리하였고, 이번 베이스라인에서는 별도의 잡음 제거를 적용하지 않았다.

6.2.2 데이터 구성

전처리 조건은 sampling rate 16kHz, mono 채널, segment 길이 8초, 화자 단위 train/validation 분리이며 최종 데이터 구성은 다음과 같다.

구분	전체 segments	전체 speakers	Train segments	Train speakers	Valid segments	Valid speakers
dementia	915	84	632	59	283	25
nodementia	1,502	96	1,091	67	411	29
합계	2,417	180	1,723	126	694	54

6.2.3 실험 1: 파이프라인 동작 확인(1 epoch)

사전학습 모델 MIT/ast-finetuned-audioset-10-10-0.4593을 기반으로 nodementia/dementia 이진 분류를 수행하였다. batch size 2, epoch 1, learning rate 1e-5, class-weighted CrossEntropyLoss 조건이며 학습 시간은 26.38분, 최대 GPU 메모리 사용량은 2.38GB였다. Validation 결과는 다음과 같다.

지표	값
loss	0.7549
accuracy	0.6254
macro precision	0.6069
macro recall	0.5775
macro F1	0.5674
nodementia recall	0.8370
dementia recall	0.3180

파인튜닝이 정상적으로 수행되고 이전 소규모 실험보다 accuracy와 macro F1이 개선됨을 확인하였다. 다만 dementia recall이 0.3180으로 낮아 치매군 segment를 정상군으로 예측하는 false negative가 많았으며(694개 중 치매군 오분류 193개), 이를 개선하기 위해 후속 실험에서 learning rate 조정, class weight 비교, threshold 조정, 화자 단위 voting 평가를 진행하였다.

6.2.4 실험 2: Learning rate 조정

실험 1에서 dementia recall이 낮게 나타난 점을 개선하기 위해 learning rate를 $1e-6$ 으로 낮추고 3 epoch 학습을 수행하였다. 나머지 조건은 실험 1과 동일하며 학습 시간은 33.94분, 최대 GPU 메모리 사용량은 2.38GB였다. Epoch별 validation 결과는 다음과 같다.

epoch	train loss	valid loss	accuracy	macro F1	nodementia recall	dementia recall
1	0.2177	0.7179	0.6614	0.6446	0.7421	0.5442
2	0.1110	0.8340	0.6801	0.6570	0.7932	0.5159
3	0.0518	0.9766	0.6671	0.6462	0.7689	0.5194

accuracy와 macro F1이 가장 높은 epoch 2를 대표 결과로 하며 epoch 2 기준 accuracy 0.6801, macro F1 0.6570, dementia recall 0.5159로 실험 1 대비 모든 지표가 개선되었다. epoch 3에서는 train loss는 감소했지만 validation loss가 증가하여 과적합 경향이 나타났다. dementia recall은 상승했으나 여전히 치매군 false negative가 137개 존재하여 아래의 threshold 조정과 화자 단위 voting 분석을 추가로 수행하였다.

6.2.4.1 Threshold 조정 분석

기본 예측은 $\text{prob_dementia} \geq 0.5$ 일 때 dementia로 분류한다. 스크리닝 서비스에서는 치매 의심군을 정상으로 놓치는 false negative를 줄이는 것이 중요하므로 validation 예측 확률을 기준으로 threshold 조정 실험을 수행하였다. 주요 결과는 다음과 같다.

threshold	accuracy	macro F1	nodementia recall	dementia recall
0.50 (기본)	0.6801	0.6570	0.7932	0.5159
0.40	0.6744	0.6597	0.7445	0.5724
0.35	0.6729	0.6604	0.7299	0.5901
0.30	0.6643	0.6548	0.7007	0.6113
0.20	0.6571	0.6527	0.6496	0.6678
0.10	0.6527	0.6525	0.5718	0.7703

threshold 0.35에서는 기본 설정 대비 macro F1이 0.6570에서 0.6604로 소폭 증가하고 dementia recall이 0.5159에서 0.5901로 증가하였다. threshold 0.10에서는 dementia recall이 0.7703까지 증가하지만 nodementia recall이 0.5718로 감소하여 정상군 오탐이 증가한다. 따라서 threshold 0.35를 macro F1 기준 대표 설정으로 제시하고 threshold 0.10은 스크리닝 목적에서 recall을 우선할 때의 trade-off 예시로 제시한다.

6.2.4.2 Speaker-level voting 분석

segment 단위 평가는 8초 음성 조각 하나하나를 독립적으로 평가하지만 실제 서비스에서는 한 사용자의 여러 발화 결과를 종합하여 위험도를 산출하는 구조가 더 자연스럽다. 이에 동일 화자의 prob_dementia 평균으로 화자 단위 최종 분류를 수행하는 voting 평가를 추가하였다.

threshold	accuracy	macro F1	nodementia recall	dementia recall
0.30 (대표)	0.7037	0.7033	0.6897	0.7200
0.35	0.7037	0.7021	0.7241	0.6800
0.40	0.7037	0.7000	0.7586	0.6400
0.50	0.6852	0.6716	0.8276	0.5200

segment 단위 대표 결과가 threshold 0.35 기준 accuracy 0.6729, macro F1 0.6604였던 것에

비해 speaker-level voting을 적용하면 threshold 0.30 기준 accuracy 0.7037, macro F1 0.7033, dementia recall 0.7200으로 향상되었다. 단일 8초 segment보다 여러 segment를 종합하는 방식이 스크리닝 목적에 더 적합할 가능성을 확인하였으며 본 과제의 최종 서비스 역시 사용자의 단일 응답이 아니라 누적 발화 기반으로 위험도를 산출할 예정이므로 speaker-level 또는 user-level aggregation 전략을 후속 실험에 반영할 필요가 있다.

6.2.5 실험 3: Class weight 미사용 비교

실험 2에서는 train 데이터의 클래스 불균형을 보정하기 위해 class-weighted cross entropy를 사용하였다. 본 실험에서는 class weight를 사용하지 않았을 때의 성능 변화를 확인하기 위해 동일한 데이터·조건(epoch 3, learning rate 1e-6)에서 class weight만 미사용으로 설정하여 비교하였다. 학습 시간은 33.81분, 최대 GPU 메모리 사용량은 3.05GB였다.

구분	accuracy	macro F1	dementia recall
실험 2: class weight 사용 (voting, threshold 0.30)	0.7037	0.7033	0.7200
실험 3: class weight 미사용 (voting, threshold 0.30)	0.7037	0.7021	0.6800
실험 2: class weight 사용 (segment, threshold 0.35)	0.6729	0.6604	0.5901
실험 3: class weight 미사용 (segment, threshold 0.25)	0.6542	0.6471	0.6290

class weight 미사용 실험에서도 speaker-level voting 기준 accuracy 0.7037을 달성하였으나, macro F1과 스크리닝 목적에서 중요한 dementia recall은 class weight를 사용한 실험 2가 더 우수하였다. segment-level에서도 class weight 사용 실험의 macro F1(0.6604)이 미사용 실험(0.6471)보다 높았다. 따라서 현재 기준 대표 실험은 class weight를 사용한 실험 2로 설정한다.

6.2.6 결론

AST 전처리·학습·평가 파이프라인이 DementiaNet 데이터에서 정상적으로 동작함을 확인하였으며 대표 설정(실험 2, speaker-level voting, threshold 0.30) 기준 accuracy 0.7037, macro F1 0.7033, dementia recall 0.7200의 예비 성능을 확보하였다. 본 결과는 DementiaNet subset 기반 예비 베이스라인으로 최종 서비스 성능으로 일반화하지 않으며 향후 직접 수집한 CIST 기반 한국어 데이터의 전처리 후 fine-tuning과 threshold-aggregation 전략 검증을 추가 실험으로 진행

할 예정이다.

6.3 음성인식(STT) 모델 비교 실험

6.3.1 실험 1: 노인 대화 음성 기반 Whisper 모델별 성능 비교

한국어 노인 대화 음성에 적합한 Whisper 후보 2종을 선별하기 위해 small, large-v1, large-v2, large-v3 네 모델을 비교하였다. 평가 데이터는 AI Hub 노인 남녀 자유 대화 음성에서 화자별 균형 무작위 추출(seed=42)한 화자 5명 × 20개, 총 100개 샘플(여성 4명·남성 1명, 60~75세, 총 약 586.7초)이며 네 모델 모두 100/100개 전사에 성공하였다. 본 실험은 최종 성능 확정이 아니라 후속 CLOVA 비교에 사용할 Whisper 후보를 좁히는 선별 실험이다.

모든 모델은 언어 ko-transcribe 작업, beam size 5, temperature [0.0, 0.2, 0.4], 반복 억제(repetition penalty 1.10, 3-gram 반복 제한), VAD(threshold 0.60), 무음 환각 감지 등 동일한 조건으로 Colab GPU에서 실행하여 모델 간 비교 가능성을 확보하였다. 한국어 WER은 띄어쓰기에 민감하므로 CER을 주 평가 지표로 사용하고, WER·문자 정확률·처리시간·RTF를 보조 지표로 기록하였다.

초기 정답 데이터에는 (SP:), (FP:) 등의 전사 태그, 띄어쓰기, 숫자·단위 표기 차이('구백그램'과 '900g' 등) 등 모델 성능과 무관한 표기 차이가 포함되어 있었다. 이를 그대로 비교하면 정상 인식도 오류로 계산되므로 참조문과 예측문 양쪽에 태그 제거, 공백 제거(CER 계산 시), 숫자·단위 표기 통일 등 동일한 평가용 정규화를 적용하였다. 원본 문장은 보존하고 평가 점수를 계산할 때만 정규화를 적용하였으며, 정규화 후에도 모델 순위(large-v2 ≈ large-v1 > small > large-v3)는 유지되었다. 최종 결과는 다음과 같다.

순위	모델	원본 CER	WER	문자 정확률	평균 처리시간	RTF
1	large-v2	5.55%	23.28%	94.45%	0.83초	0.142
2	large-v1	5.67%	22.90%	94.33%	0.80초	0.137
3	small	8.26%	29.84%	91.74%	0.40초	0.068
4	large-v3 (원본)	12.46%	22.64%	87.54%	1.01초	0.172

large-v2가 CER 기준 1위지만 large-v1과의 차이는 0.13%p에 불과하며 통계적 유의성을 검증하지 않았으므로 두 모델은 사실상 동급으로 해석하는 것이 적절하다. 한편 모델별 평균만으로는 드러나지 않는 화자 편차도 확인되었는데 특히 large-v3는 일부 화자에서는 우수했지만(남 75세 화자 CER 4.07%) 특정 화자에서 환각이 집중되어(여 69세 화자 CER 20.15%) 안정성이 낮았

다.

large-v3에서는 '감사합니다', '시청해주셔서 감사합니다', '영상편집 ○○○' 등 실제 음성에 없는 영상 자막성 환각 문구가 반복적으로 확인되었다. 알려진 문구를 제거하면 CER이 12.46%에서 7.99%로 낮아지지만 이는 모델 원본 성능이 개선된 것이 아니라 결과를 후처리한 값이므로 large-v3는 후처리 점수만으로 후보에 포함하지 않았다. small은 처리속도는 가장 빠르지만 CER이 약 2.6%p 높아 제외하였다. 따라서 1차 실험의 결론으로 large-v2와 large-v1을 후속 CLOVA 비교 대상으로 선정하였다.

6.3.2 실험 2: CLOVA Speech 및 상위 Whisper 모델 비교

실험 1에서 선발한 large-v1, large-v2와 CLOVA Speech의 성능을 비교하였다. 평가 데이터는 실험 1의 100개 중 화자별 6개씩 동일하게 구성한 30개(총 185.9초)이며 특정 화자의 발화가 전체 결과를 과도하게 좌우하지 않도록 하였다. CLOVA Speech는 장문 인식 API를 로컬 WAV 업로드·동기식 방식으로 호출하였고(잡음 제거 사용, 화자 분리 미사용), 30/30개 전사에 성공하였다. 세 모델 모두 실험 1과 동일한 참조문과 정규화 기준을 적용하여 비교하였다. 최종 결과는 다음과 같다.

순위	모델	CER	문자 정확률	WER	평균 처리시간
1	CLOVA Speech	2.61%	97.39%	14.73%	3.29초
2	large-v1	4.21%	95.79%	20.59%	0.81초
3	large-v2	5.13%	94.87%	24.99%	0.85초

CLOVA Speech가 CER과 WER 모두 가장 우수하였으며 가장 좋은 Whisper 모델인 large-v1 대비 CER을 절대 1.61%p(상대 약 38.2%), large-v2 대비 절대 2.53%p(상대 약 49.2%) 줄였다. 반면 처리시간은 파일당 평균 3.29초로 Whisper(0.81~0.85초)보다 약 4배 길었다. 다만 CLOVA 처리 시간에는 파일 업로드, 네트워크 왕복, 서버 인식 시간이 모두 포함되고 Whisper는 Colab GPU 내부 처리시간이므로 속도 비교에는 실행 환경 차이가 포함되어 있다.

CLOVA의 주요 오류는 '요요 → 여유'처럼 음향적으로 유사한 단어의 대체, 짧은 단어 누락, 조사·음절 대체 등 대부분 실제 발화와 유사한 음절 수준의 오류였으며 Whisper large-v3에서 나타났던 영상 자막성 환각 문구는 확인되지 않았다. 또한 CER 5.88%인 문장이 띄어쓰기 차이만으로 WER 83.33%로 계산되는 사례가 확인되어 이번 실험에서도 CER을 주 지표로 사용하는 것이 적절함을 재확인하였다.

한편 실험 1의 100개에서는 large-v2가 근소하게 우수했지만 이번 30개에서는 large-v1(4.21%)이 large-v2(5.13%)를 앞섰다. 이는 두 모델의 실제 차이가 작고 표본 선택에 따라 순위가 바뀔 수 있음을 보여주며 large-v2가 항상 우수하다기보다 두 모델이 비슷하고 이번 30개에서는 v1이 우수했다고 해석해야 한다.

본 실험의 한계는 다음과 같다. 30개 표본은 실험 1의 100개에서 다시 선택하였으므로 독립된 테스트셋이 아니고 화자가 5명뿐이며 성별 분포(여 4명, 남 1명)가 불균형하다. 모든 파일이 짧은 발화이므로 긴 대화에서의 성능은 확인하지 않았고, 평균 CER은 파일별 평균이므로 짧은 파일과 긴 파일이 동일한 가중치를 가지며 모델 간 차이에 대한 신뢰구간이나 통계적 유의성 검정은 수행하지 않았다.

평가 관점	우수 모델	판단
인식 정확도	CLOVA Speech	CER 2.61%로 가장 우수
로컬 처리속도	large-v1	약 0.81초로 CLOVA보다 약 4배 빠름
오프라인 사용	Whisper	외부 API와 네트워크 불필요
이번 30개 Whisper 정확도	large-v1	v2보다 CER 0.92%p 우수
전체 100개 Whisper 정확도	large-v2 $\approx$ large-v1	차이가 0.13%p로 매우 작음

종합하면 인식 정확도에서는 CLOVA Speech가 가장 우수하였다. 다만 API 비용, 네트워크 의존성, 처리 지연을 고려하면 로컬·실시간 처리에는 large-v1이, 정확도 중심의 서버 처리에는 CLOVA Speech가 적합하다. 최종 도입 결정 전에 새로운 화자가 포함된 독립 데이터로 한 번 더 검증할 예정이다.

6.4 텍스트 분석(KcELECTRA) 파이프라인 검증

현재는 한국어 정상군과 한국어 치매·인지저하 의심군 데이터가 함께 준비되어 있지 않으므로 본 단계에서 KcELECTRA는 정상/치매 분류 학습을 수행하지 않고 파이프라인 검증에 집중하였다. 구체적으로 '한국어 음성 → Whisper STT → 텍스트 전처리 → KcELECTRA 토큰나이징 → 모델 입력 → 출력 생성'으로 이어지는 전체 흐름이 정상적으로 동작하는지를 AI Hub 노인 남녀 자유 대화 음성 데이터로 확인하였다. 즉 KcELECTRA는 이번 단계에서 성능 실험이 아니라 파이프라인 검증을 완료한 상태이며 직접 수집한 한국어 정상·의심 데이터가 확보되는 대로 파인튜닝과 성능 평가를 진행할 예정이다.

7. 참고 문헌

- [1] 박찬호. (2023). 인지기능 장애 환자의 음성 데이터를 활용한 치매 예측 분류에 관한 연구. 성균관대학교 일반대학원 스마트팩토리융합학과 석사학위논문.
- [2] 황혜진, 임석현. (2025). BERT를 이용한 발화 기반 치매 환자 위험 탐지 모델. 한국정보통신학회논문지, 29(8), 1009-1018.
- [3] Zheng, Q., Xu, Z., Li, N., Wang, Y., Zhang, T., & Jing, J. (2024). Age-related hearing loss in older adults: etiology and rehabilitation strategies. *Frontiers in Neuroscience*, 18, 1428564.